Chapitre 2 : Contributions de Recherche et Positionnement du Mécanisme IECA

Ce projet présente le mécanisme IECA (Interaction-based Explanation of Collective reAsoning). Notre contribution s’oppose précisément aux trois limites structurelles identifiées dans la littérature scientifique récente et s'articule autour de trois piliers.

2.1. Du "Black-Box" Statistique à la "White-Box" Cognitive

Comme souligné par Domènech I Vila et al. (2022), les méthodes globales classiques (LIME, SHAP) considèrent l'agent comme une boîte noire et échouent à identifier la véritable cause d'une décision dans un environnement coopératif. La littérature la plus récente, notamment les travaux sur le Layered Prompting (2025), démontre que pour obtenir des traces interprétables, l'explicabilité doit être intégrée au cœur même de l'architecture décisionnelle en forçant l'agent à externaliser son raisonnement.
Notre apport : En réponse à cette limite, le mécanisme IECA permet de lever cette opacité grâce à l'architecture ReAct (Yao et al., 2023), s'inscrivant pleinement dans la philosophie du Layered Prompting. Plutôt que de déduire les intentions d’un agent depuis l’extérieur, IECA oblige l’agent LLM à produire une trace explicite de sa cognition ([THOUGHT]) avant chaque action. L'explication n'est donc plus une rationalisation post-hoc détachée de la réalité (un risque majeur mis en évidence par Turpin et al., 2023), mais une extraction directe du processus de délibération. Nous passons ainsi d’une XAI descriptive à une XAI véritablement cognitive et causale en "boîte blanche".

2.2. Dépassement de la limite temporelle : De l'instant t=1 à la dynamique séquentielle

La plupart des approches causales ou contrastives se contentent d’expliquer un réflexe isolé à un instant donné (souvent noté t=1), indépendamment de l’évolution de la conversation. Or, comme le démontrent les avancées majeures telles que le framework MACIE (Multi-Agent Causal Intelligence Explainer) de Weinberg (2026), l'état de

l'art exige désormais le recours au raisonnement contrefactuel interventionnel pour quantifier mathématiquement l'influence d'un agent sur les autres. Dans un MAS, une action n'a de sens que par les réactions qu'elle anticipe ou provoque (la dimension "mécanique").

Notre contribution : En nous inspirant de la logique du framework CEMA (Gyevnar et al., 2024) et en adéquation avec les principes de MACIE (2026), nous avons mis en place un mécanisme de rollback et de simulation contrefactuelle. Cependant, là où CEMA nécessite un simulateur probabiliste lourd (non applicable aux textes générés par des LLM), IECA utilise le LLM lui-même comme simulateur. Quand il explique une décision prise à l'instant t, IECA crée des mondes contrefactuels ("Que se serait-il passé si l'agent X n'avait pas agi ainsi ?") afin d'observer l'effet domino de l'action sur les tours suivants (t+1, t+2). Notre contribution montre que la vraie explication d'une décision dans un MAS se trouve dans ses conséquences séquentielles à long terme, dépassant ainsi la limite des explications figées à t=1.

2.3. Modélisation Causale via les Graphes de Connaissances (Knowledge Graphs)

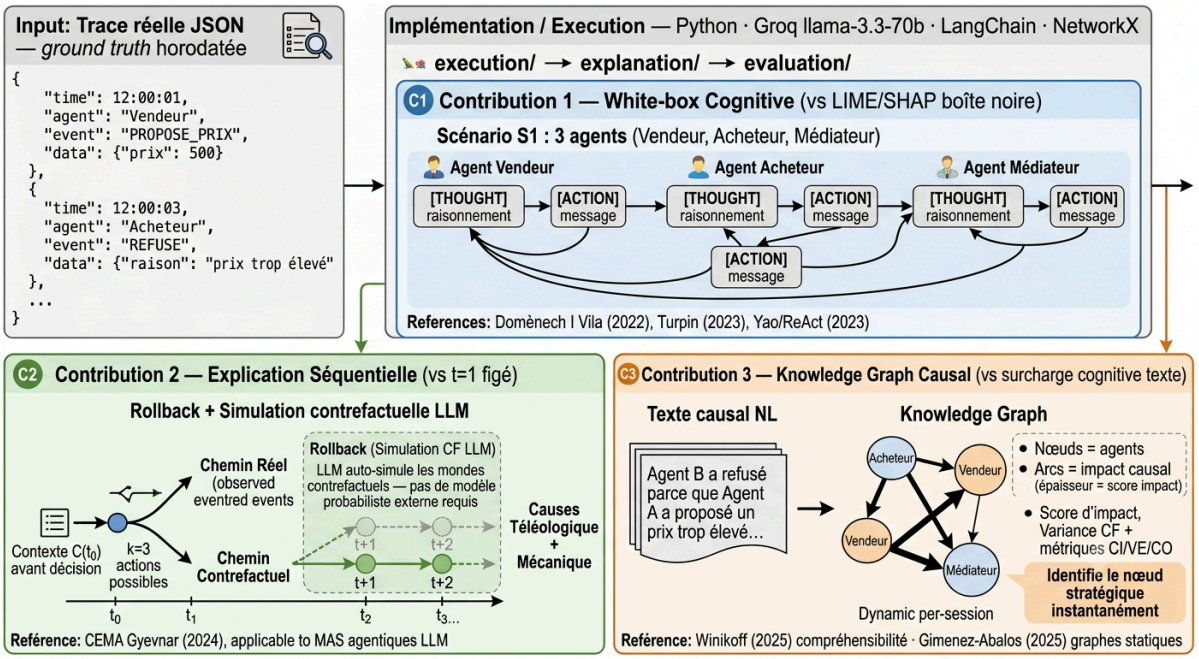
Une des limites des systèmes purement textuels (comme CoCoXplain, Mindlin et al., 2026) réside dans la surcharge cognitive de l'utilisateur humain. Plus le nombre d'agents augmente, plus l'explication en langage naturel devient longue, dense et difficile à auditer rapidement, ce qui contredit le critère de compréhensibilité défini par Winikoff et al. (2025). L'architecture récente du système CausalAgent (Zhu et al., 2026) prouve que l'avenir de l'XAI passe par la traduction des inférences causales complexes en des représentations visuelles dynamiques.

Notre contribution : Pour remédier à cette limite de surcharge cognitive, et en alignement avec les conclusions de CausalAgent (2026), IECA traduit de façon automatique les causalités mécaniques et téléologiques identifiées lors des simulations contrefactuelles en un Causal Influence Graph (Graphe de Connaissances) généré de façon dynamique. À la différence des graphes de politiques statiques (Gimenez-Abalos et al., 2025), ce graphe modélise visuellement le poids des

influences inter-agents pour une session donnée. Les agents sont modélisés par des nœuds, et l'épaisseur des arêtes représente le score d'impact causal (calculé à partir de la variance des résultats contrefactuels). Ce Knowledge Graph permet à un superviseur humain de repérer d'emblée le « nœud stratégique » (l'agent ayant eu l'influence la plus forte) sans avoir à parcourir l'ensemble des traces textuelles.

2.4. Architecture du mécanisme IECA

Le mécanisme IECA est codé sous la forme d'un prototype fonctionnel en Python, en utilisant le modèle Llama-3.3-70b via l'API Groq. L'architecture logicielle respecte la structure décrite ci-dessus en trois phases : le module execution/ gère les agents ReAct et l'enregistrement de la trace, le module explanation/ implémente le rollback, la génération d'alternatives et la simulation contrefactuelle, et le module evaluation/ calcule les métriques CI, VE et CO. Le Causal Influence Graph est construit dynamiquement à partir des scores d'impact calculés lors des simulations contrefactuelles, en s'appuyant sur la bibliothèque NetworkX.



Références bibliographiques mobilisées

Domènech I Vila, M., et al. (2022). Testing Reinforcement Learning Explainability Methods in a Multi-Agent Cooperative Environment. Frontiers in Artificial Intelligence and Applications.

- Gimenez-Abalos, V., et al. (2025). Policy Graphs and Intention: answering 'why' and 'how' from a telic perspective. AAMAS.
- Gyevnar, B., et al. (2024). Causal Explanations for Sequential Decision-Making in Multi-Agent Systems. AAMAS.
- Layered Prompting (2025). Structuring Interactions for Explainable Multi-Agent Systems.
- Mindlin, D., et al. (2026). Towards Co-Constructed Explanations: A Multi-Agent Reasoning-Based Conversational System for Adaptive Explanations. HAI.
- Turpin, M., et al. (2023). Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting. NeurIPS.
- Weinberg, A. I. (2026). MACIE: Multi-Agent Causal Intelligence Explainer for Collective Behavior Understanding. arXiv preprint arXiv:2511.15716.
- Winikoff, M., et al. (2025). A Scoresheet for Explainable AI. AAMAS.
- Yao, S., et al. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. ICLR.
- Zhu, J., Chen, W., & Cai, R. (2026). CausalAgent: A Conversational Multi-Agent System for End-to-End Causal Inference. IUI Companion '26.