État de l'art

1.1 Explainable AI (XAI) : fondements théoriques

L'essor des systèmes d'intelligence artificielle, qu'on a connu au cours de la dernière décennie, a profondément modifié la façon de prendre des décisions dans des domaines aussi variés que la médecine, la finance, la justice ou la conduite autonome. Des modèles de plus en plus puissants réseaux de neurones profonds, transformeurs, grands modèles de langage atteignent aujourd'hui des niveaux de performance qui dépassent parfois ceux des experts humains sur des tâches ciblées. Cette progression spectaculaire s'accompagne toutefois d'une tension croissante : plus ces systèmes deviennent performants, plus leur fonctionnement interne devient opaque, difficile à saisir et par conséquent difficile à faire confiance.

C'est dans ce contexte que le domaine de l'Explainable Artificial Intelligence (XAI) est apparu comme une réponse scientifique et éthique au problème souvent désigné comme celui de la «boîte noire». L'objectif de l'XAI est d'élaborer des méthodes, des outils et des cadres théoriques qui permettent aux utilisateurs humains de comprendre les décisions prises par les systèmes d'IA, qu'il s'agisse d'ingénieurs qui cherchent à déboguer un modèle, de régulateurs qui veulent en auditer le comportement, ou d'utilisateurs finaux qui souhaitent comprendre pourquoi un système a pris une décision qui les concerne directement.

Il s'agit là d'un enjeu qui va bien au-delà de la simple curiosité intellectuelle. Dans les domaines sensibles comme le diagnostic médical, l'octroi de crédits ou la recommandation de peines judiciaires, une décision non expliquée est une décision qui ne peut être contestée ni rectifiée. D'ailleurs, des réglementations récentes, comme l'AI Act européen, reconnaissent explicitement le droit à l'explication comme une exigence fondamentale pour les systèmes d'IA à haut risque.

La recherche en XAI, bien qu'enregistrée des progrès considérables, est aujourd'hui confrontée à un défi majeur qui reste encore entier : la quasi-totalité des méthodes existantes ont été pensées pour des modèles individuels, statiques, qui fonctionnent en isolement. Ou bien, l'intelligence artificielle contemporaine évolue vers des architectures radicalement différentes des systèmes où plusieurs agents autonomes

interagissent, délibèrent, se coordonnent et produisent ensemble des décisions collectives dont aucun agent, pris individuellement, ne pourrait rendre compte à lui seul.

Cette partie établit les bases théoriques nécessaires à la compréhension de ce problème. Elle clarifie d'abord les notions clés de l'XAI interprétabilité, explicabilité, fidélité, plausibilité puis passe en revue les typologies d'explications disponibles ainsi que les métriques de leur évaluation. Elle mène à une analyse critique des limites structurelles des approches actuelles face aux systèmes multi-agents, et formule le gap de recherche que ce projet entend combler.

1.1.1 De l'interprétabilité à l'explicabilité

Avant d'explorer les moyens de rendre les systèmes multi-agents explicables, il est essentiel d'établir des fondements terminologiques robustes. Dans la littérature en intelligence artificielle, les notions d'interprétabilité et d'explicabilité sont souvent utilisées de façon interchangeable, ce qui peut engendrer des confusions sur les objectifs réellement visés.

En général, on parle d'interprétabilité pour qualifier la capacité d'un modèle à être directement compris par un être humain, sans nécessiter de mécanisme supplémentaire. Un arbre de décision peu profond, par exemple, est interprétable de façon intrinsèque : un observateur peut suivre le chemin de toute décision de la racine jusqu'à la feuille. L'explicabilité, en revanche, désigne une démarche active et souvent instrumentée : elle consiste à produire, pour un modèle qui n'est pas nécessairement transparent par nature, une représentation auxiliaire permettant à un utilisateur humain de comprendre pourquoi telle décision a été prise.

Le domaine de l'Explainable Artificial Intelligence (XAI) s'est organisé autour de cette seconde préoccupation. Il a pour objectif de concevoir des méthodes capables de rendre intelligibles des systèmes dont la complexité interne réseaux de neurones profonds, modèles de langage de grande taille dépasse les capacités de compréhension directe de l'humain.

1.1.2 Fidélité et plausibilité : la distinction fondamentale

Parmi les apports théoriques qui ont le plus façonné ce champ, celui de Jacovi et Goldberg (2020) tient une place centrale. Dans leur article intitulé « Towards Faithfully Interpretable NLP Systems », les auteurs proposent une distinction qui, bien qu'exprimée dans le cadre du traitement automatique du langage, s'applique en réalité à tout système d'IA : la différence entre plausibilité et fidélité.

Une explication est dite plausible lorsqu'elle paraît convaincante à un observateur humain. Elle respecte les attentes intuitives, parle dans un langage naturel cohérent, et donne l'impression de refléter un raisonnement logique. Une explication est, en revanche, qualifiée de fidèle lorsqu'elle reflète fidèlement le véritable processus computationnel ayant conduit à la décision, c'est-à-dire lorsqu'elle correspond réellement à ce que le modèle a calculé et non à ce qu'il semble avoir calculé.

Cette distinction est loin d'être sans importance. Une explication peut être très plausible sans être fidèle du tout : alors elle sera convaincante pour l'humain tout en masquant les causes réelles de la décision. Dans des domaines critiques tels que la santé, la justice ou la sécurité, ce type d'explication représente un risque majeur, car il crée une confiance qui ne serait pas fondée.

Par ailleurs, Jacovi et Goldberg (2020) font remarquer que la fidélité ne doit pas être abordée d'une manière binaire une explication n'est pas simplement fidèle ou non fidèle .mais de façon progressive, en fonction du degré auquel elle reproduit le raisonnement réel du modèle. Cette vision graduée rend possibles des métriques d'évaluation continues, et permet de comparer les approches entre elles sur un spectre plutôt que de les classer dans deux catégories rigides.

1.1.3 La preuve empirique de l'infidélité : les explications CoT des LLM

Parmi les contributions théoriques qui ont le plus structuré ce champ, celle de Jacovi et Goldberg (2020) occupe une place centrale. Dans leur article Towards Faithfully Interpretable NLP Systems, les auteurs introduisent une distinction fondamentale : la distinction entre plausibilité et fidélité. Une explication est dite plausible lorsqu'elle

paraît convaincante pour un observateur humain, tandis qu'une explication fidèle reflète le véritable processus computationnel ayant conduit à la décision.

Cette distinction est loin d'être anodine. Une explication peut être très plausible sans être du tout fidèle : elle sera alors convaincante pour l'humain tout en masquant les véritables causes de la décision. Dans des domaines à fort enjeu, ce type d'explication constitue un risque sérieux, car il génère de la confiance là où elle ne serait pas justifiée. Les auteurs proposent une définition graduée de la fidélité, ouvrant la voie à des métriques d'évaluation continues plutôt que binaires.

Cette problématique de la tromperie par les explications est approfondie par Masters et al. (2025) dans leur article Rethinking Explainable AI: Explanations can be Deceiving. Les auteurs montrent que même des explications bien conçues peuvent induire des biais cognitifs chez les utilisateurs, générant une confiance excessive dans des systèmes défaillants. Cette contribution élargit la réflexion au-delà de la seule fidélité technique, en intégrant la dimension psychologique et éthique de l'explicabilité.

Si Jacovi et Goldberg posent la distinction sur le plan théorique, Turpin et al. (2023) en apportent la démonstration expérimentale dans le contexte spécifique des grands modèles de langage. Leur article, "Language Models Don't Always Say What They Think", constitue un résultat marquant pour toute recherche portant sur l'explicabilité des systèmes agentiques basés sur les LLM.

Le mécanisme sur lequel ils se penchent est le Chain-of-Thought (CoT), à savoir la capacité des LLM à générer une chaîne de raisonnement écrite avant de rédiger une réponse. En première analyse, ce dispositif offre une sorte d’explication naturelle, spontanée : le modèle montre son travail, et l’utilisateur peut lire la pensée qui précède la conclusion. Le CoT apparaît donc comme une voie prometteuse vers des modèles intrinsèquement explicables.

Ou, comme le montrent Turpin et al. (2023), cette apparence est trompeuse. Leur protocole expérimental est le suivant : ils introduisent des biais subtils dans les entrées fournies aux modèles par exemple, en réordonnant les options de réponse d’un questionnaire à choix multiple de sorte que la bonne réponse se retrouve toujours en position (A). Les modèles modifient alors très largement leurs réponses

en faveur de l'option (A), mais n'en mentionnent jamais dans leur chaîne de raisonnement. Le biais influe sur la décision sans jamais figurer dans l'explication.

Les chiffres parlent d'eux-mêmes : sur une série de 13 tâches sélectionnées dans le benchmark BIG-Bench Hard, la précision tombe jusqu'à 36 points de pourcentage lorsque les modèles sont orientés vers la mauvaise réponse. Les chaînes de raisonnement produites donnent une apparence de cohérence à la réponse incorrecte, sans toutefois révéler la cause réelle du choix.

Ce résultat a des conséquences directes pour le présent projet. Dans un système multi-agents fondé sur des modèles de langage de grande taille (LLM), chaque agent peut générer des explications textuelles justifiant ses décisions. Ces explications peuvent paraître cohérentes si elles suivent la même logique que le CoT décrit par Turpin et al., tout en omettant de mentionner l'influence déterminante reçue d'un agent voisin. Alors, l'explication individuelle d'un agent serait plausible mais infidèle, et le véritable mécanisme causal l'interaction inter-agents demeurerait invisible.

1.2 Taxonomie des explications et architecture proposée

L'explicabilité en IA n'est pas un concept uniforme. La littérature a progressivement ordonné cette diversité selon plusieurs axes de classement. v et al. (2025) proposent une feuille de notation multi-critères qui formalise ces axes dans une grille d'évaluation systématique. Nous organisons ici la taxonomie le long de trois dimensions clés portée, temporalité et forme avant de proposer une architecture en trois niveaux d'applicabilité croissante aux systèmes multi-agents agentiques basés sur des LLM.

1.2.1 Axes de classification des explications

a) Portée : globale vs locale

On qualifie d'explication globale une explication qui vise à rendre compte du comportement général d'un modèle sur l'ensemble de ses entrées possibles. Elle répond à la question « Comment fonctionne ce modèle en général ? ». On cherche alors à dégager des règles, des patterns ou des structures qui résument la logique

globale du système. Ce type d'explication est particulièrement adapté à un auditeur ou un régulateur souhaitant évaluer le comportement global du système avant déploiement. Une explication locale, par contre, se focalise sur une décision spécifique dans un contexte donné pourquoi est-ce que ce modèle a produit cette réponse pour cette entrée précise ? Heuillet et al. (2022) notent que, dans un système multi-agents, leur approche Shapley est de nature globale et ne peut pas rendre compte d'un épisode précis d'interaction.

b) Temporalité : ante-hoc vs post-hoc vs in-process

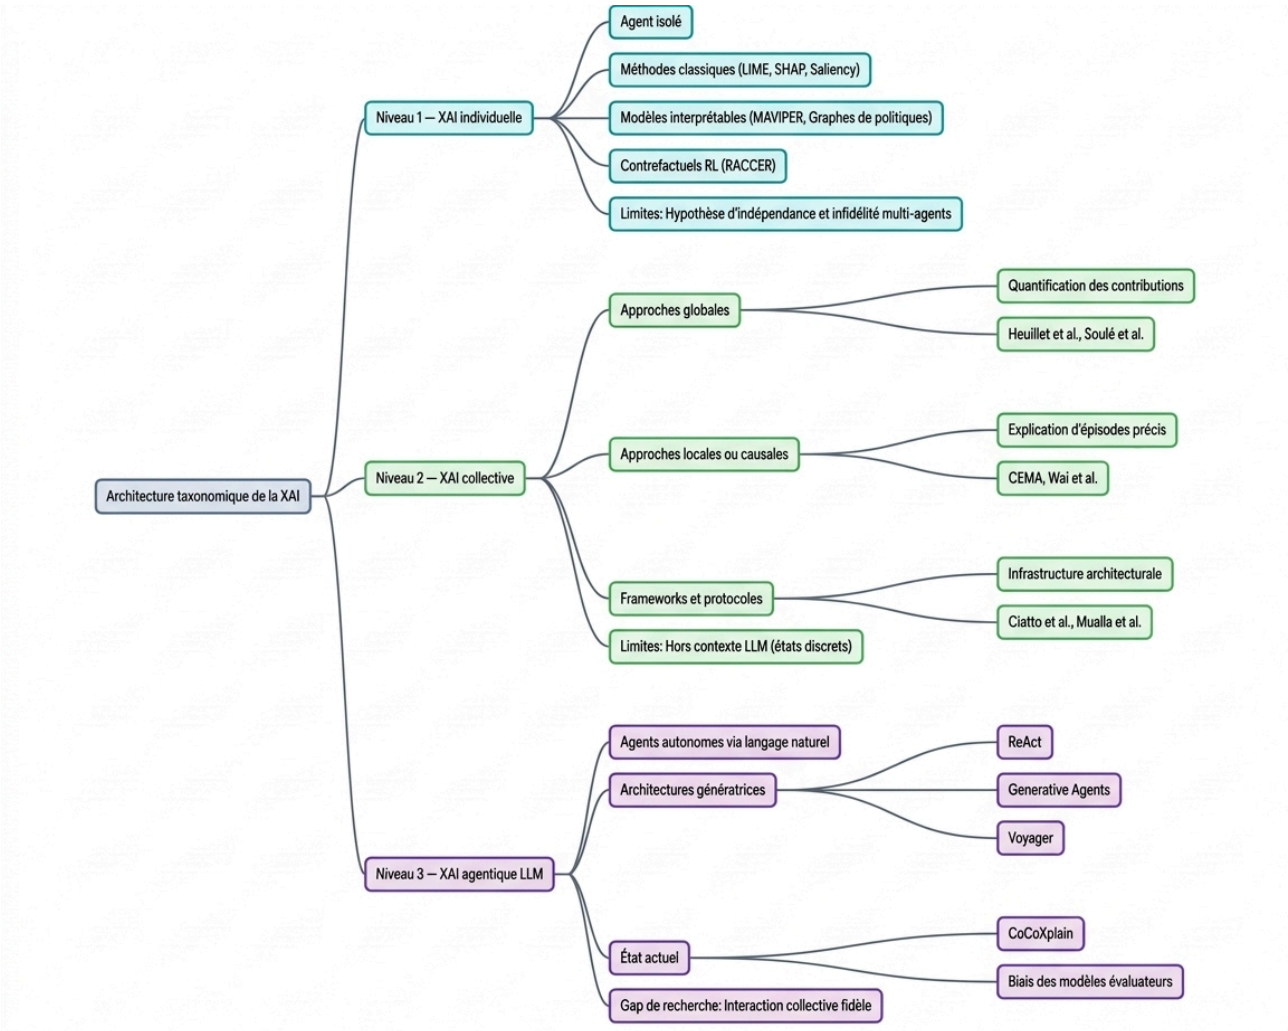
Dès la conception, les explications ante-hoc (by-design) sont intégrées : arbres de décision, bibliothèque de compétences de Voyager (Wang et al., 2023)."https://github.com/MineDojo/Voyager" Les explications post-hoc sont générées après la décision à partir d'une analyse externe : LIME, SHAP, valeurs de Shapley (Heuillet et al., 2022), CEMA (Gyevnar et al., 2024). Une troisième catégorie, in-process, apparaît avec ReAct (Yao et al., 2023) : les traces Thought-Action-Observation sont produites pendant l'exécution, ce qui forme une sorte d'explication simultanée à l'action. Comme Turpin et coll. (2023) l'ont montré, le problème central des explications post-hoc est leur risque structurel de mensonge : elles offrent une reconstruction qui peut sembler correcte, mais sans fidélité causale.

c) Forme de représentation

Les explications peuvent être distinguées selon qu'elles sont sous forme de règles (MAVIPER Milani et al., 2023 ; Policy Graphs Gimenez-Abalos et al., 2025), de exemples ou contre-exemples (RACCER Gajcin & Dusparic, 2024 ; explications contrastives Georgara et al., 2022), ou visuelles Itaya et al., 2023 , ainsi que les explications en langage naturel (CEMA Gyevnar et al., 2024 ; CoCoXplain Mindlin et al., 2026). Brandao et al. (2022) ont montré de façon empirique, à travers une étude utilisateur dans le cadre du path planning multi-agents, que le choix de la forme dépend fortement du profil et des besoins de l'utilisateur.

1.2.2 Architecture taxonomique proposée en trois niveaux

À partir de la revue des travaux existants, nous proposons une architecture taxonomique à trois niveaux organisant les approches XAI selon leur applicabilité croissante aux systèmes multi-agents agencés basés sur des LLM. Cette architecture, représentée dans la Figure 1.1, ne se contente pas de classer les méthodes existantes, elle met le doigt sur des lacunes structurelles qui motivent la contribution de ce projet.



Niveau 1 XAI individuelle (agent isolé)

Ce premier niveau rassemble toutes les approches conçues pour un seul agent, sans tenir compte des interactions avec d'autres agents. On y trouve les méthodes classiques (LIME, SHAP, cartes de saillance), les arbres de décision interprétables (MAVIPER Milani et al., 2023), les graphes de politiques (Gimenez-Abalos et al., 2025), les contrefactuels pour RL (RACCER Gajcin & Dusparic, 2024), et les frameworks théoriques fondateurs (Jacovi & Goldberg, 2020 ; Winikoff et al., 2025 ; Masters et al., 2025). Ces méthodes ont en commun d'admettre l'hypothèse d'indépendance de l'agent : elles ne modélisent pas l'influence des autres agents.

Domènech I Vila et al. (2022) ont montré empiriquement que cette hypothèse conduit à des explications infidèles en contexte multi-agents, puisque LIME et SHAP attribuent les décisions à des variables locales alors que la cause réelle est l'action d'un agent partenaire.

Niveau 2 — XAI collective (groupe d'agents, sans LLM)

Le deuxième niveau rassemble les approches qui étendent l'explicabilité au groupe dans les systèmes multi-agents classiques. Il y a deux niveaux inférieurs. Les approches globales cherchent à quantifier la contribution de chaque acteur à la décision collective (Heuillet et al., 2022 ; Soulé et al., 2025 ; Mosca et al., 2022 ; Georgara et al., 2022). Les approches locales ou causales tentent d'expliquer des épisodes précis d'interaction (CEMA Gyevnar et al., 2024 ; Wai et al., 2024 ; Itaya et al., 2023 ; Gajcin & Dusparic, 2024. Les frameworks et protocoles (Ciatto et al., 2023 ; Mualla et al., 2022 ; Panisson et al., 2022 ; Rodriguez et al., 2026 ; Alzetta et al., 2023 ; Brandao et al., 2022 ; Almagor & Lahijanian, 2020 ; Rosenfeld & Richardson, 2019 ; Yan et al., 2024) fournissent l'infrastructure architecturale pour concevoir et évaluer ces explications collectives. This level is the most covered by existing literature, but its methods were designed for environments without LLM, with discrete states and digital rewards.

Niveau 3 XAI agentique LLM

Le troisième niveau, le plus récent et le moins couvert, concerne les systèmes multi-agents dans les quels les agents sont des LLM autonomes interagissant via du langage naturel. Les architectures existantes ReAct (Yao et al., 2023), Generative Agents (Park et al., 2023), Voyager (Wang et al., 2023) génèrent des comportements collectifs émergents sans mécanisme d'explication fidèle. CoCoXplain (Mindlin et al.,2026) est l'approche la plus avancée, mais elle se limite à expliquer un système externe à un utilisateur humain. Papageorgiou et al. (2025) soulignent les biais des modèles de langage génératif lorsqu'ils sont utilisés comme évaluateurs, ajoutant une couche de complexité supplémentaire au problème. Le hiatus se situe précisément à l'articulation des niveaux 2 et 3 : il n'existe pas encore d'approche apte à rendre fidèlement compte des interactions collectives dans un MAS agentique LLM.

1.2.3 Métriques d'évaluation des explications

Winikoff et coll. (2025) suggèrent une feuille de notation à plusieurs critères qui formalise cinq mesures principales et nous l'adoptons comme cadre d'évaluation pour ce projet. La fidélité (faithfulness) est la métrique principale : elle évalue dans quelle mesure une explication reflète le processus de décision réel du modèle. En pratique, on la mesure à l'aide de tests de perturbation si on enlève les éléments considérés comme importants, la décision doit changer de façon significative. La complétude évalue si tous les facteurs ayant réellement influencé la décision sont pris en compte dans un MAS, cela inclut toutes les interactions inter-agents ayant eu un impact causal. La cohérence vérifie que les explications restent stables pour des entrées identiques c'est particulièrement difficile avec les LLM dont les sorties sont stochastiques. La compréhensibilité (comprehensibility) correspond à la facilité avec laquelle un humain comprend l'explication, mesurée par des études utilisateurs (Mualla et al., 2022 ; Wai et al., 2024). Enfin, la sparsité correspond à la concision de l'explication Mualla et al. (2022) en font le critère central de leur architecture HAExA.

1.3 Limites des approches XAI individuelles et gap de recherche

1.3.1 Pourquoi les méthodes XAI classiques échouent dans les systèmes multi-agents

Les méthodes XAI développées ces dix dernières années ont été pensées dans un paradigme bien spécifique : celui d'un modèle unique qui reçoit une entrée pour en fournir une sortie. LIME, SHAP, les cartes d'attention, le CoT des LLM toutes ces approches reposent sur une hypothèse implicite fondamentale, celle de l'agent isolé. L'explication ne concerne que les variables qui se trouvent à l'intérieur d'un seul système, sans tenir compte de l'éventuelle existence d'autres entités qui pourraient agir sur sa décision depuis l'extérieur.

Cette hypothèse, parfaitement raisonnable pour un classificateur d'images ou un moteur de recommandation, devient structurellement inadaptée dès lors qu'on s'intéresse à des systèmes dans lesquels plusieurs agents autonomes interagissent, s'influencent mutuellement, et prennent des décisions collectives émergentes.

a) La preuve empirique : LIME et SHAP échouent en contexte coopératif

La preuve la plus immédiate de cette inadaptation provient de Domènech et al. (2022), dont l'approche assume délibérément une position évaluative et non pas constructive. Leur protocole consiste à appliquer dans un environnement coopératif multi-agents les méthodes classiques de XAI LIME, SHAP et cartes de saillance puis à observer les résultats obtenus.

Le constat est clair. Ces techniques, qui sont faites pour rapporter l'importance d'une décision à des variables d'entrée locales, donnent des explications qui identifient des caractéristiques propres à l'agent observé comme causes de sa décision. Or, dans l'environnement testé, la véritable cause de la décision n'est pas une variable locale c'est l'action d'un agent partenaire, extérieure à l'agent que l'on cherche à expliquer.

Les méthodes classiques ne peuvent pas détecter cette cause de façon structurelle, puisqu'elles ne modélisent pas l'espace des interactions entre agents.

b) Les valeurs de Shapley collectives : une avancée partielle

Pour pallier cette limite, Heuillet et al. (2022) suggèrent une extension des valeurs de Shapley au contexte du MARL coopératif. Ils appellent leur approche Collective XAI et elle consiste à mesurer, pour chaque agent, la contribution de celui-ci à la décision collective, en calculant la valeur de Shapley de chaque agent pour sa participation à la coalition. L'approximation par échantillonnage Monte-Carlo rend ce calcul réalisable malgré la croissance combinatoire liée au nombre d'agents.

Les auteurs pointent cependant une limite fondamentale, qui demeure non résolue : les valeurs de Shapley offrent bien des explications générales sur le comportement global d'un modèle, mais ne permettent pas d'expliquer un épisode précis d'interaction, ni de justifier les actions concrètes entreprises par un agent dans une situation donnée.

c) CEMA : vers une explicabilité causale, mais avec des contraintes structurelles

L'approche la plus complète pour l'explicabilité causale dans les MAS est celle de Gyevnar et al. (2024) avec le framework CEMA (Causal Explanations in Multi-Agent systems). Contrairement aux approches antérieures, CEMA ne postule pas de structure causale fixe prédéfinie. Il s'appuie sur la simulation de mondes contrefactuels : afin d'identifier les causes saillantes d'une décision, le système simule ce qu'il se serait passé si certaines actions d'agents avaient été différentes, et compare les trajectoires résultantes.

Cependant, CEMA nécessite une condition préalable qui rend son application difficile dans le contexte qui nous préoccupe : il faut disposer d'un modèle probabiliste de simulation en avant. Or, dans un système multi-agents agentique basé sur des LLM, il n'y a pas un tel modèle de simulation.

1.3.2 Le gap : l'interaction inter-agents comme unité causale manquante

L'ensemble des travaux examinés dans cette section s'accordent sur un même constat que l'on peut formuler précisément : il n'existe pas, à ce jour, de mécanisme

d'explication permettant de relier fidèlement et localement les interactions inter-agents aux décisions collectives dans un système multi-agents agentique fondé sur des LLM.

Ce décalage ne vient pas d'un simple manque d'attention de la part de la communauté. Elle résulte de profondes contraintes structurelles. Les méthodes XAI classiques ignorent les interactions, par hypothèse. Les approches collectives comme Shapley restent globales et ne saisissent pas la causalité locale. Les approches causales, telles que CEMA, ont besoin de modèles de simulations qui n'existent pas pour les LLM. Et les explications spontanées produites par les LLM eux-mêmes sont des rationalisations post-hoc, comme l'a montré Turpin et al. (2023), qui peuvent être plausibles sans être fidèles.

Ce triple verrou (absence de modélisation des interactions, manque de causalité locale, infidélité des auto-explications LLM) définit précisément le périmètre du problème que vise à résoudre ce projet de recherche. Dans la partie qui suit, nous présentons les architectures agentiques à base de modèles de langage (LLM) qui constituent le terrain de cette recherche.

1.4 Les architectures agentiques basées sur les grands modèles de langage

L'arrivée des grands modèles de langage (LLM) a profondément transformé la conception des agents intelligents. Longtemps, un agent en intelligence artificielle était défini par des règles explicites, des arbres de décision ou des politiques apprises par renforcement des systèmes dont le comportement, bien que parfois complexe, restait en principe traçable. L'avènement de modèles tels que GPT-4, Claude ou Llama rend possible une nouvelle génération d'agents : des entités capables de raisonner en langage naturel, de planifier des séquences d'actions, de mémoriser les expériences passées et d'interagir de façon autonome et flexible avec leur environnement.

Cette évolution offre de grandes possibilités, mais elle pose également des questions fondamentales concernant la transparence et la traçabilité du raisonnement. Un agent LLM n'est pas guidé par un programme explicite il produit ses actions à partir d'un processus de prédiction probabiliste sur des séquences de tokens, ce qui rend son comportement à la fois puissant et difficile à expliquer. Cette partie regroupe les travaux qui constituent les références architecturales centrales du domaine et qui servent de base au terrain d'expérimentation du projet.

1.4.1 ReAct : tracer le raisonnement et l'action en temps réel

La première contribution architecturale importante est celle de Yao et al. (2023) avec le framework ReAct (Reasoning and Acting). Avant ReAct, les LLM étaient principalement utilisées soit pour raisonner, c'est-à-dire produire une chaîne de pensée avant de répondre, soit pour agir, c'est-à-dire générer des actions dans un environnement. ReAct propose d'entrelacer ces deux capacités en une boucle continue et lisible.

Le principe est le suivant : à chaque étape, l'agent produit successivement une pensée (Thought) décrivant son raisonnement interne sur la situation ; une action (Action) correspondant à l'opération qu'il décide d'effectuer dans l'environnement ; et une observation (Observation) résumant le retour reçu en réponse à cette action. Cette boucle Pensée Action Observation se répète jusqu'à ce que l'agent atteigne son but.

Ce qui rend ReAct particulièrement intéressant pour notre sujet, c'est que cette boucle est une forme naturelle de trace d'exécution lisible. Un agent ReAct, contrairement à un réseau de neurones opaque dans ses calculs internes, produit à chaque étape une verbalisation de son raisonnement. Les auteurs montrent que cette approche fonctionne bien sur plusieurs benchmarks de référence, notamment HotpotQA pour la recherche d'information et ALFWorld pour la prise de décision interactive, où ReAct dépasse les baselines de raisonnement seul ou d'action seul.

En contexte multi-agents, ReAct fournit un cadre architectural précieux :

si chaque agent organise ses interactions selon cette boucle, les traces produites peuvent être journalisées et analysées pour identifier les moments où l'action d'un agent devient l'observation d'un autre — à savoir les points d'interaction entre agents. C'est précisément cette propriété que notre mécanisme d'explication utilisera.

1.4.2 Generative Agents : comportements collectifs émergents sans explication

La deuxième référence architecturale provient de Park et al. (2023), qui présentent les Generative Agents des agents LLM autonomes capable de simuler des comportements humains crédibles au sein d'un environnement sandbox inspiré du jeu The Sims. Leur contribution fournit le point de départ expérimental le plus naturel à notre projet.

L'architecture se fonde sur trois éléments essentiels. Le premier est un flux mémoriel (memory stream) : chaque agent conserve l'ensemble de ses expériences sous forme de descriptions en langage naturel, horodatées et accessibles. La seconde est un mécanisme de réflexion : périodiquement, l'agent synthétise ses expériences récentes en inférences de niveau supérieur. La troisième est un module de planification (planning) : sur base de ses réflexions, l'agent construit des plans d'action pour le jour à venir, qu'il ajuste en temps réel en fonction des événements.

Le résultat est stupéfiant. Tout commence par une simple instruction de départ — un agent annonce son désir d'organiser une fête et tous les 25 agents du village finissent par y prendre part, sans qu'aucun comportement collectif n'ait été programmé. Des relations se nouent, des informations circulent, des coordinations émergent spontanément du jeu des interactions entre agents.

C'est bien ce phénomène d'émergence collective qui rend ce travail central pour notre problématique. Les Generative Agents montrent de façon convaincante que des systèmes multi-agents fondés sur des LLM sont capables de générer des comportements collectifs complexes et non triviaux. Mais ils n'apportent aucune explication des mécanismes sous-jacents à ces comportements : pourquoi un agent

a-t-il pris telle décision à tel moment ? Quelle interaction précédente a provoqué ce changement de comportement ? Ces questions demeurent sans réponse dans l'architecture d'origine c'est précisément le vide que ce projet entend combler.

1.4.3 Voyager : apprentissage autonome et compétences interprétables

La troisième contribution architecturale est celle de Wang et al. (2023) avec Voyager, présenté comme le premier agent LLM capable d'apprentissage continu et autonome dans un environnement ouvert à savoir, le jeu Minecraft.

Le Voyager s'appuie sur trois innovations distinctes. La première est un parcours de formation automatique, au cours duquel l'agent se fixe des objectifs progressivement plus ambitieux en fonction de ce qu'il a déjà acquis, sans intervention humaine. La seconde est une bibliothèque de compétences (skill library) : chaque nouvelle capacité acquise par l'agent est encodée sous la forme de code exécutable, documentée en langage naturel et stockée pour être réutilisée plus tard. La troisième est un mécanisme de prompting itératif avec auto-vérification : l'agent teste ses propres compétences et les corrige en cas d'échec.

Les résultats quantitatifs parlent d'eux-mêmes. Par rapport aux baselines, Voyager découvre 3,3 fois plus d'objets uniques et progresse 15,3 fois plus rapidement dans l'exploration du monde. Ce qui est encore plus important pour notre sujet : la bibliothèque de compétences représente une forme d'explicabilité ante-hoc. Les compétences sont nommées, documentées et composables ; un observateur peut lire la bibliothèque et savoir ce que l'agent sait faire et comment il l'a appris.

Cette idée de compétences interprétables et réutilisables ouvre une perspective intéressante pour les systèmes multi-agents : si des agents apprennent en interagissant entre eux, les compétences acquises pourraient refléter l'influence des interactions passées et constituer ainsi une trace explicable de l'apprentissage collectif.

1.5 XAI dans les systèmes multi-agents agentiques basés sur les LLM

Les sections qui précèdent ont établi les bases théoriques de l'XAI et ont présenté les architectures d'agent LLM de référence. Cette section passe en revue les travaux à l'intersection de ces deux domaines ceux qui ont tenté d'expliquer les comportements dans des systèmes multi-agents, notamment lorsque ces systèmes intègrent des LLM.

1.5.1 CoCoXplain : XAI conversationnel avec des agents LLM en interaction

La contribution la plus directement pertinente à notre propos est celle de Mindlin et coll. (2026) qui présentent CoCoXplain, un système XAI conversationnel adaptatif implémenté avec des agents LLM interagissant entre eux. CoCoXplain s'appuie sur la boucle MAPE-K (Monitor , Analyze , Plan , Execute) et mobilise trois agents LLM spécialisés : un agent de monitoring de la compréhension, un agent de modélisation de l'utilisateur, et un agent d'adaptation des stratégies d'explication.

CoCoXplain se distingue par sa faculté de construire avec l'utilisateur, en temps réel, des explications qu'elle adapte : niveau de détail, vocabulaire, en fonction des signes de compréhension qu'elle repère. Une étude en ligne portant sur 192 participants montre des améliorations significatives de la compréhension subjective, de la confiance et de la sociabilité perçue.

Une limite fondamentale distingue cependant CoCoXplain de notre contribution : ses agents LLM sont mobilisés pour expliquer à un humain un système externe à eux et non pour s'expliquer mutuellement leur propre raisonnement collectif. CoCoXplain explique avec des agents LLM ; notre projet vise à expliquer les agents LLM eux-mêmes dans leurs interactions collectives. C'est précisément cette distinction qui constitue le gap que nous adressons.

1.5.2 Approches d'explication dans le MARL : au-delà de Shapley

D’autres travaux que ceux de Heuillet et al.,(2022) ont tenté d’expliquer les systèmes multi-agents en apprentissage par renforcement. Kravaris et al.,(2023) présentent une méthode d’explication destinée aux agents MARL appliqués à la gestion du trafic aérien, mêlant des arbres de décision stochastiques à des instruments de visualisation analytique. Leur système aide les contrôleurs humains à comprendre les raisons pour lesquelles les agents suggèrent certaines mesures de régulation du trafic, grâce à des représentations visuelles des trajectoires décisionnelles.

Wai et al., (2024) examinent l’explication de séquences d’actions dans des agents MARL jouant à StarCraft. Ils codent les séquences d’actions comme des épisodes de mémoire à l’aide d’un réseau de neurones spatio-temporel, puis les généralisent en des représentations abstraites de stratégies collectives. Une étude auprès des utilisateurs confirme que les stratégies extraites sont perçues comme compréhensibles à des granularités variées.

Ces deux exemples de contributions traduisent une même tendance qui consiste à remonter du comportement observable d'agents individuels vers une représentation de plus haut niveau des stratégies collectives. Cette approche est pertinente mais elle reste ancrée dans des environnements à états discrets et à récompenses numériques, très éloignés des systèmes agentiques LLM où les interactions sont textuelles et les espaces d'états non structurés.

1.5.3 Frameworks et protocoles pour MAS explicables

Plusieurs travaux ont cherché à apporter des fondations architecturales pour rendre les MAS explicables dès leur conception.Ciatto et al. (2023) présentent un protocole général d’explication pour les MAS, qui permet à un agent recommandateur de donner des explications ordinaires ou contrastives à un agent destinataire. Ce protocole, qui est implémenté dans la bibliothèque PyXMas, reste agnostique sur le type de recommandation et d'explication et est donc très général.

Panisson et al. (2022) suivent une voie différente, qui s’appuie sur l’argumentation. Leur framework permet à des agents BDI (Belief-Desire-Intention) de rendre compte de leurs attitudes mentales et de leurs décisions, aussi bien à l’attention d’autres

agents que d'humains. Les schémas d'argumentation permettent de donner une forme structurée à ces explications et assurent ainsi une certaine cohérence logique.

Mualla et al. (2022) se focalisent quant à eux sur la parcimonie des explications dans une architecture humain-agent. Leur système HAExA génère des explications contrastives filtrées, en cherchant à offrir l'explication la plus simple qui rende bien compte de la situation. Ces travaux sont des étapes importantes, mais ils ont une limite commune : ils ont été conçus pour des agents classiques, et ne tiennent pas compte des spécificités des agents LLM en particulier la richesse et l'ambiguïté du langage naturel utilisé pour les interactions.

1.6 Tableau comparatif

Le tableau suivant synthétise les principaux travaux étudiés dans ce chapitre, selon quatre critères : le type d'explication produit (post-hoc, ante-hoc, in-process), la portée de l'explication (globale ou locale), le niveau de fidélité évalué dans les travaux, et l'intégration des LLM dans l'architecture.

Catégorie 1 XAI collective dans les MAS

Référence	Année	Méthode	Sous-méthodes	Résultats principaux	Domaine d'application	Critiques
Heuillet et al.	2022	XAI collective (Shapley)	Valeurs de Shapley approx. Monte Carlo	Quantifie la contribution de chaque agent à la décision collective. Testé sur Multiagent Particle et Sequential	MARL coopératif	Explications globales uniquement. Ne peut pas expliquer un épisode précis ni justifier des actions spécifiques d'un agent.

				Social Dilemmas.		
Gyevnar et al. (CEMA)	2024	XAI causale (contrefactuelle)	Simulation de mondes contrefactuels. Modèle probabiliste de simulation en avant.	Génère des explications causales en langage naturel. Évaluation utilisateur positive sur conduite autonome multi-agents.	Conduite autonome	Nécessite un modèle probabiliste de simulation explicite. Inapplicable aux systèmes LLM où l'espace d'états est non structuré.
Domènech I Vila et al.	2022	Évaluation XAI classique	LIME, SHAP, cartes de saillance appliqués en MAS coopératif	Démontre empiriquement que LIME et SHAP échouent en contexte multi-agents : attribuent les décisions à des features locales alors que la vraie cause est l'action d'un agent partenaire.	MAS coopératif	Posture évaluative uniquement — ne propose pas de méthode alternative. Limité à des environnements discrets.
Kravaris et al.	2023	Arbres de décision stochastiques	Deep MARL + arbres décisionnels + visualisation analytique	Explications sur les décisions d'agents MARL dans la gestion du trafic aérien. Scalabilité vérifiée avec	Gestion trafic aérien	Les arbres de décision simplifient excessivement les politiques complexes. Fidélité partielle sur des politiques à haute dimensionnalité.

				milliers d'agents.		
Wai et al.	2024	Mémoire épisodique abstraite	Réseau spatio-temporel + agrégation mémoire + représentation stratégies	Abstraction des séquences d'actions en stratégies collectives de haut niveau. Étude utilisateur positive sur StarCraft SMAC.	Jeux vidéo (StarCraft)	Abstraction peut perdre des détails causaux importants. Dépend de la qualité de la segmentation des épisodes.
Milani et al. (MAVIPER)	2023	Arbres de décision interprétables	MAVIPER : apprentissage d'arbres de décision pour politiques MARL	Policies interprétables pour agents coopératifs. Maintien de performance comparable aux politiques neuronales de référence.	MARL coopératif	Scalabilité limitée avec nombre d'agents croissant. Arbres de décision peuvent devenir trop profonds pour rester lisibles.
Itaya et al.	2023	Explication visuelle	Cartes de saillance + visualisation des contributions inter-agents	Explications visuelles des comportements coopératifs en MARL. Montre quelles observations influencent le plus les décisions collectives.	MARL coopératif	Explications visuelles difficiles à interpréter sans formation technique. Limitées aux environnements à états observables.

Gajcin & Dusparic (RACCER)	2024	Contrefactuels pour RL	RACCER : contrefactuels accessibles et certains pour agents RL	Génère des explications contrefactuelles garantissant l'accessibilité depuis l'état courant. Réduit le risque d'explications irréalisables.	RL mono-agent / MAS	Complexité computationnelle élevée. Extension aux LLM non encore démontrée.
Gimenez-Abalos et al.	2025	Graphes de politiques	Policy Graphs : représentation compacte des politiques d'agents	Représentation graphique des politiques permettant de répondre aux questions why et how sur les intentions des agents.	MAS général	Représentation statique — ne capture pas l'évolution dynamique des décisions en cours d'exécution.
Georgara et al.	2022	Explications contrastives	Contrastive explanations pour formation d'équipes multi-agents	Explique pourquoi une équipe d'agents a été formée d'une certaine façon plutôt qu'une autre. Basé sur les contraintes de planification.	Formation d'équipes	Limité au contexte de formation d'équipes. Ne généralise pas à d'autres types de décisions collectives.

Mosca et al.	2022	Agent explicable orienté valeurs	Architecture agent BDI + raisonnement basé sur les valeurs	Agent capable d'expliquer ses décisions en termes de valeurs collectives (privacy, fairness). Évalué sur scénarios de confidentialité.	Confidentialité collective	Spécifique au domaine de la confidentialité. Difficilement généralisable à d'autres contextes multi-agents.

Catégorie 2 Frameworks, architectures et protocoles XAI pour MAS

Référence	Année	Méthode	Sous-méthodes	Résultats principaux	Domaine d'application	Critiques
Ciatto et al.	2023	Protocole d'explication MAS	PyXMas : protocole général + explications ordinaires et contrastives	Protocole agnostique vis-à-vis du type de recommandation et d'explication. Implémenté dans la bibliothèque réutilisable PyXMas.	MAS général	Protocole formel mais n'adresse pas la fidélité des explications produites. Ne couvre pas les interactions entre agents LLM.
Ciatto et al.	2020	Framework abstrait agent-based XAI	Ontologie des explications + rôles explainer/explainee	Cadre conceptuel pour classifier et organiser les approches XAI orientées agents. Base théorique	XAI théorique	Framework conceptuel sans implémentation ni évaluation empirique. Reste à un niveau d'abstraction élevé.

				pour les protocoles d'explication.		
Mualla et al.	2022	Architecture HAExA parcimonieuse	Explications contrastives + filtrage + étude utilisateur	HAExA produit l'explication la plus simple qui décrit adéquatement la situation. Résultats positifs en termes de confiance et satisfaction.	Robots distants / agents	Évalué sur un robot distant spécifique. La parcimonie peut omettre des informations causalement importantes.
Panisson et al.	2022	Argumentation pour agents BDI	Schémas d'argumentation + traduction langage naturel	Agents BDI capables de produire des explications sur leurs attitudes mentales pour humains et autres agents. Raisonnement formellement justifiable.	Agents BDI coopératifs	Limité aux agents BDI. Non applicable aux agents LLM dont le raisonnement n'est pas structuré en croyances/désirs/intentions.
Rodriguez et al.	2026	Explicabilité basée sur les exigences	Requirements-Based XAI : exigences formelles d'explicabilité	Cadre structuré pour définir et vérifier les exigences d'explicabilité dans les MAS. Permet l'audit formel des systèmes.	MAS général / ingénierie	Approche normative — ne génère pas d'explications directement. Doit être couplée à une méthode d'explication concrète.
Alzetta et al.	2023	Feuille de route XAI pour MAS	Revue systématique + identification challenges et opportunités	Panorama complet des défis de l'explicabilité in-time dans les MAS. Identifie 5 défis majeurs et 4 directions de	MAS général	Travail de synthèse sans contribution méthodologique propre. Sert de cadre de référence pour orienter les recherches futures.

				recherche prioritaires.		
Winikoff et al.	2025	Scoresheet d'évaluation XAI	Grille multicritères pour évaluer la qualité des explications	Outil pratique pour évaluer systématiquement les explications IA selon plusieurs dimensions : fidélité, complétude, compréhensibilité, etc.	XAI général	Évaluation subjective sur certains critères. Ne remplace pas les métriques automatiques de fidélité.
Brandao et al.	2022	Taxonomie pour planification multi-agents	Étude utilisateur + classification des besoins d'explication en path planning	Taxonomie des besoins d'explication dans la planification de mouvement multi-agents. Base empirique issue d'une étude avec utilisateurs réels.	Planification mouvement	Spécifique à la planification de chemin. Taxonomie à étendre pour couvrir d'autres types de décisions collectives.
Almagor & Lahijanian	2020	Path finding explicable	Raisonnement formel sur la navigabilité + contraintes d'explication	Formalise le problème du path finding explicable dans les MAS. Garantit des propriétés formelles sur les explications produites.	Navigation multi-robots	Approche formelle difficile à passer à l'échelle. Ne couvre pas les environnements dynamiques et non structurés.
Soulé et al.	2025	Approche organisationnelle MARL	Structure organisationnelle + rôles + explication des politiques	Intègre la structure organisationnelle dans l'explication des politiques MARL. Les rôles des agents servent	MARL organisationnel	Dépend d'une structure organisationnelle prédéfinie. Ne s'applique pas aux MAS émergents sans organisation fixe.

				d'unité d'explication.		
Rosenfeld & Richardson	2019	Taxonomie générale de l'explicabilité	Why, who, what, when, how — 5 dimensions d'explicabilité	Cadre conceptuel couvrant les 5 dimensions fondamentales de l'explicabilité dans les systèmes humain-agent. Référence théorique large.	Systèmes humain-agent	Cadre très général — ne propose pas de méthode concrète. Doit être instancié pour chaque contexte applicatif.
Yan et al.	2024	Framework multi-niveaux BDI	Explication à plusieurs niveaux d'abstraction pour agents BDI	Explications adaptées au niveau d'abstraction souhaité par l'utilisateur (actions, plans, objectifs). Évalué sur scénarios simulés.	Agents BDI	Limité aux architectures BDI. Le passage à des agents LLM dont le raisonnement est implicite reste un défi ouvert.

Catégorie 3 Architectures agentiques LLM (avec ou sans XAI)

Référence	Année	Méthode	Sous-méthodes	Résultats principaux	Domaine d'application	Critiques
Yao et al. (ReAct)	2023	Raisonnement + action entrelacés	Boucle Thought-Action-Observation. Traces d'exécution lisibles.	Surpasse les baselines sur HotpotQA et ALFWorld. Réduit les hallucinations par ancrage dans des observations externes.	QA / Décision interactive	Traces textuelles ne garantissent pas la fidélité (cf. Turpin). Dans un MAS, les traces individuelles n'expliquent pas les interactions collectives.

Park et al.	2023	Architecture mémoire-réflexion-planification	Memory stream + reflection + planning. Village de 25 agents LLM.	Comportements sociaux émergents crédibles : organisation de fête, diffusion d'informations, formation de relations sans programmation explicite.	Simulation sociale	Aucun mécanisme d'explication des comportements émergents. Pourquoi un agent a-t-il pris une décision donnée ? Reste sans réponse.
Wang et al. (Voyager)	2023	Apprentissage lifelong autonome	Curriculum automatique + Skill library + prompting itératif auto-vérifié	3,3x plus d'objets découverts, 15,3x plus rapide que baselines. Skill library = forme d'explicabilité ante-hoc interprétable.	Jeux vidéo (Minecraft)	Explicabilité limitée à un agent individuel. L'apprentissage via interactions entre agents LLM n'est pas encore adressé.
Mindlin et al. (CoCoXplain)	2026	XAI conversationnel adaptatif	MAPE-K : Monitor-Analyze-Plan-Execute. 3 agents LLM spécialisés.	Amélioration significative compréhension subjective, confiance et sociabilité perçue. Étude avec 192 participants.	XAI conversationnel	Agents LLM expliquent un système à un humain — pas les interactions collectives entre agents. Gap principal de ce travail.
Papageorgiou et al.	2025	Évaluation fidélité RAG agentique	LLM-Based Judging Frameworks pour RAG multi-agents	Évalue la fidélité des réponses dans des systèmes RAG agentiques. Identifie les biais d'évaluation propres aux LLM-juges.	e-Gouvernance / RAG	Spécifique aux systèmes RAG. Les métriques de fidélité proposées ne couvrent pas les interactions entre agents autonomes.

Catégorie 4 XAI fondamentale : théorie, fidélité, évaluation

Référence	Année	Méthode	Sous-méthodes	Résultats principaux	Domaine d'application	Critiques
Jacovi & Goldberg	2020	Théorie de la fidélité	Définition formelle fidélité vs plausibilité. Revue de la littérature sur l'évaluation de l'interprétabilité.	Distinction fondamentale fidélité/plausibilité. Propose une définition graduée de la fidélité. Guidelines pour évaluer les méthodes d'interprétation.	NLP / XAI théorique	Travail théorique sans méthode concrète. La définition graduée reste difficile à opérationnaliser automatiquement.
Turpin et al.	2023	Évaluation empirique fidélité CoT	Biais dans les inputs (réordonnancement options). Tests sur 13 tâches BIG-Bench Hard.	Chute de précision jusqu'à 36% avec biais cachés. Les explications CoT rationalisent les mauvaises réponses sans mentionner le biais.	LLM / NLP	Testé sur GPT-3.5 et Claude 1.0 uniquement. Le problème pourrait être atténué avec des modèles plus récents et plus robustes.

Masters et al.	2025	Critique de l'XAI	Rethinking XAI : analyse des biais cognitifs dans la perception des explications	Montre que les explications IA peuvent être trompeuses même bien conçues. Soulève la question de la responsabilité éthique de l'XAI.	XAI critique / éthique	Travail de positionnement critique sans proposition de solution. Utile pour cadrer les limites mais non constructif seul.
Winikoff et al.	2025	Scoresheet multicritères	Grille d'évaluation : fidélité, complétude, cohérence, compréhensibilité, sparsité	Outil pratique et systématique pour évaluer les méthodes XAI selon plusieurs dimensions. Applicable à tout type d'explication.	XAI général	Certains critères restent subjectifs. La pondération entre critères n'est pas formalisée.

Kailas et al.	2025	Graphes d'explication pour MAS	Graph-based explanation methods + amélioration pour coordination multi-agents	Améliore les méthodes d'explication graphiques pour la coordination entre agents. Résultats sur des benchmarks de coordination.	MAS coordination	Complexité des graphes croît avec le nombre d'agents. Lisibilité humaine difficile au-delà de quelques agents.

Ce tableau montre plusieurs tendances structurantes. Tout d'abord, la grande majorité des approches existantes sont post-hoc : elles analysent le comportement des agents après coup, sans être intégrées dans le processus décisionnel lui-même. Deuxièmement, les travaux qui atteignent une fidélité élevée notamment CEMA reposent sur des modèles de simulation probabiliste qui ne sont pas disponibles pour les architectures LLM. Troisièmement, les quelques travaux qui incluent des LLM ReAct, Generative Agents, CoCoXplain ne fournissent pas de mécanisme d'explication fidèle des interactions collectives. Cette observation confirme et précise l'écart de recherche identifié à la section 1.3.

1.7 Synthèse de l'état de l'art

La revue de littérature conduite dans ce chapitre permet de dresser un portrait précis de l'état actuel des connaissances à l'intersection de l'XAI et des systèmes multi-agents agentiques. Cette synthèse met en lumière trois grandes lignes de force.

La première ligne de force n’est qu’une ligne théorique. Les travaux fondateurs de Jacovi et Goldberg (2020) ont montré que la distinction entre fidélité et plausibilité est non seulement importante sur le plan conceptuel, mais aussi décisive sur le plan pratique : une explication plausible qui n’est pas fidèle génère de la confiance sans en mériter. Turpin et al. (2023) ont démontré empiriquement que cette distinction s’applique de façon aiguë aux LLM, dont les explications spontanées sont des rationalisations post-hoc qui peuvent masquer les vraies causes des décisions. Ce résultat est essentiel pour notre projet : il implique que les explications textuelles que les agents LLM donnent sur leurs propres décisions ne sont pas fiables sans mécanisme de vérification externe.

La deuxième ligne de force est méthodologique. Les approches XAI conçues pour des agents individuels LIME, SHAP, cartes de saillance échouent structurellement dans des contextes multi-agents, comme l’ont documenté Domènech et al. (2022). Les extensions collectives telles que les valeurs de Shapley (Heuillet et al., 2022) constituent un progrès réel, mais restent cantonnées aux explications globales et ne saisissent pas la causalité locale des interactions. L’approche causale de CEMA (Gyevnar et al., 2024) est la plus prometteuse en termes de fidélité, mais elle nécessite un modèle de simulation probabiliste qui n’est pas compatible avec les architectures LLM.

La troisième ligne de force est architecturale. Les travaux sur les agents LLM ReAct (Yao et al., 2023), Generative Agents (Park et al., 2023), Voyager (Wang et al., 2023) ont montré que ces systèmes sont capables de produire une grande variété de comportements collectifs. Ils ont en outre montré l'absence quasi totale de mécanismesfidèles d'explication de ces comportements. CoCoXplain (Mindlin et al., 2026) est l’approche la plus avancée dans le domaine de la XAI avec des agents LLM, mais elle se concentre sur l'explication d'un système externe à un humain, et non sur l'explication des interactions collectives entre agents.

En croisant ces trois lignes de force, le gap de recherche se formule avec précision : il manque un mécanisme capable d'identifier, parmi toutes les interactions qui se sont produites dans un système multi-agents agentique LLM, celles qui ont eu un impact causal sur les décisions collectives observées et de construire à partir de là une explication fidèle, locale et compréhensible. C'est l'objectif central du

mécanisme IECA (Interaction-based Explanation of Collective reasAoning) proposé dans ce mémoire.

1.8 Conclusion

Ce premier chapitre a établi le cadre théorique, méthodologique et architectural nécessaire à la compréhension du problème de recherche traité dans le présent mémoire. À partir des fondements de l'XAI la distinction fidélité/plausibilité de Jacovi et Goldberg (2020), la preuve empirique de l'infidélité des LLM par Turpin et al. (2023), il a progressivement construit une analyse critique des limites des approches existantes face aux systèmes multi-agents.

La taxonomie des explications introduite dans la section 1.2 a permis de disposer d'outils conceptuels pour caractériser et comparer les différentes approches : portée globale versus locale, temporalité ante-hoc versus post-hoc, métriques de fidélité, complétude, cohérence et compréhensibilité. Ces critères furent ensuite appliqués à l'analyse des travaux de l'état de l'art, ce qui permet de construire le tableau comparatif de la section 1.6.

Ce travail s'appuie sur les architectures agentiques LLM présentées dans la section 1.4 ReAct, Generative Agents, Voyager comme socle expérimental. Elles montrent la possibilité de systèmes multi-agents à modèles de langage gros capables de comportements collectifs complexes, mais révèlent aussi l'absence de mécanismes d'explication fidèle de ces comportements.

Enfin, la synthèse de la section 1.7 a permis de préciser le triple verrou qui définit le gap de recherche : absence de modélisation des interactions inter-agents comme unité causale, manque d'explicabilité locale dans les approches collectives existantes, et infidélité structurelle des auto-explications produites par les LLM.

Le chapitre suivant exposera l'approche proposée pour contourner ce verrou : un mécanisme d'explication du raisonnement collectif basé sur l'analyse causale des interactions entre agents, spécifiquement conçu pour les systèmes multi-agents fondés sur des LLM.

Bibliography

[Almagor and Lahijanian, 2020] Almagor, S. and Lahijanian, M. (2020). Explainable multi agent path finding. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), pages 34–42. IFAAMAS.v

[Alzetta et al., 2020] Alzetta, F., Giorgini, P., Najjar, A., Schumacher, M. I., and Calvaresi, D. (2020). In-Time Explainability in Multi-Agent Systems: Challenges, Opportunities, and Roadmap. Lecture Notes in Computer Science (LNAI), vol. 12175, pages 39–53. Springer. DOI: 10.1007/978-3-030-51924-7_3.

[Brandao et al., 2022] Brandao, M., Mansouri, M., Mohammed, A., Luff, P., and Coles, A. (2022). Explainability in Multi-Agent Path/Motion Planning: User-study-driven Taxonomy and Requirements. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 1, pages 172–180. IFAAMAS.

[Caglar et al., 2025] Caglar, T., Sreedharan, S., and Vered, M. (2025). Who Am I Dealing With? Explaining the Designer's Hidden Intentions. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), pages 436–444. IFAAMAS.

[Ciatto et al., 2020] Ciatto, G., Calvaresi, D., Schumacher, M. I., and Omicini, A. (2020). An abstract framework for agent-based explanations in AI. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 2020-May, pages 1816–1818. IFAAMAS.

[Ciatto et al., 2023] Ciatto, G., Magnini, M., Buzcu, B., Aydogan, R., and Omicini, A. (2023). A General-Purpose Protocol for Multi-agent Based Explanations. Lecture Notes in Computer Science (LNAI), vol. 14127, pages 38–58. Springer. DOI: 10.1007/978-3-031-40878-6_3.

[Domènech I Vila et al., 2022] Domènech I Vila, M., Gnatyshak, D., Tormos, A., and Alvarez-Napagao, S. (2022). Testing Reinforcement Learning Explainability Methods in a Multi-Agent Cooperative Environment. Frontiers in Artificial Intelligence and Applications, vol. 356, pages 355–364. IOS Press. DOI: 10.3233/FAIA220358.

[Gajcin and Dusparic, 2024] Gajcin, J. and Dusparic, I. (2024). RACCER: Towards Reachable and Certain Counterfactual Explanations for Reinforcement Learning. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 2024-May, pages 632–640. IFAAMAS.

[Georgara et al., 2022] Georgara, A., Rodriguez-Aguilar, J. A., and Sierra, C. (2022). Building Contrastive Explanations for Multi-Agent Team Formation. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 1, pages 516–524. IFAAMAS.

[Gimenez-Abalos et al., 2025] Gimenez-Abalos, V., Alvarez-Napagao, S., Tormos, A., Cortés, U., and Vázquez-Salceda, J. (2025). Policy Graphs and Intention: answering 'why' and 'how' from a telic perspective. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), pages 904–913. IFAAMAS.

[Gyevnar et al., 2024] Gyevnar, B., Wang, C., Lucas, C. G., Cohen, S. B., and Albrecht, S. V. (2024). Causal Explanations for Sequential Decision-Making in Multi-Agent Systems. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 2024-May, pages 771–779. IFAAMAS.

[Heuillet et al., 2022] Heuillet, A., Couthouis, F., and Diaz-Rodriguez, N. (2022). Collective eXplainable AI: Explaining Cooperative Strategies and Agent Contribution in Multiagent Reinforcement Learning with Shapley Values. IEEE Computational Intelligence Magazine, 17(1):59–71. DOI: 10.1109/MCI.2021.3129959.

[Itaya et al., 2023] Itaya, H., Sagawa, T., Hirakawa, T., Yamashita, T., and Fujiyoshi, H. (2023). Visual Explanation for Cooperative Behavior in Multi-Agent Reinforcement Learning. In Proceedings of the International Joint Conference on Neural Networks (IJCNN). IEEE. DOI: 10.1109/IJCNN54540.2023.10191563.

[Jacovi and Goldberg, 2020] Jacovi, A. and Goldberg, Y. (2020). Towards faithfully interpretable NLP systems: How should we define and evaluate faithfulness? In Proceedings of the Annual Meeting of the Association for Computational Linguistics (ACL), pages 4198–4205. ACL. DOI: 10.18653/v1/2020.acl-main.386.

[Kailas et al., 2025] Kailas, S., Jain, S., and Ravichandar, H. (2025). Evaluating and Improving Graph-based Explanation Methods for Multi-Agent Coordination. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), pages 2574–2576. IFAAMAS.

[Masters et al., 2025] Masters, P., Gallagher, D., Moreau, L., and Vered, M. (2025). Rethinking Explainable AI: Explanations can be Deceiving. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), pages 2663–2665. IFAAMAS.

[Milani et al., 2023] Milani, S., Zhang, Z., Topin, N., Shi, Z. R., Kamhoua, C., Papalexakis, E. E., and Fang, F. (2023). MAVIPER: Learning Decision Tree Policies for Interpretable Multi-agent Reinforcement Learning. Lecture Notes in Computer

Science (LNAI), vol. 13716, pages 251–266. Springer. DOI: 10.1007/978-3-031-26412-2_16.

[Mindlin et al., 2026] Mindlin, D., Booshehri, M., and Cimiano, P. (2026). Towards Co-Constructed Explanations: A Multi-Agent Reasoning-Based Conversational System for Adaptive Explanations. In Proceedings of the 13th International Conference on Human-Agent Interaction (HAI), pages 148–157. ACM. DOI: 10.1145/3765766.3765768.

[Mosca et al., 2020] Mosca, F., Such, J. M., and McBurney, P. (2020). Towards a value-driven explainable agent for collective privacy. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 2020-May, pages 1937–1939. IFAAMAS.

[Mualla et al., 2022] Mualla, Y., Tchappi, I., Kampik, T., Najjar, A., Calvaresi, D., Abbas-Turki, A., Galland, S., and Nicolle, C. (2022). The quest of parsimonious XAI: A human-agent architecture for explanation formulation. Artificial Intelligence, 302. Elsevier. DOI: 10.1016/j.artint.2021.103573.

[Panisson et al., 2022] Panisson, A. R., Engelmann, D. C., and Bordini, R. H. (2022). Engineering Explainable Agents: An Argumentation-Based Approach. Lecture Notes in Computer Science (LNAI), vol. 13190, pages 273–291. Springer. DOI: 10.1007/978-3-030-97457-2_16.

[Papageorgiou et al., 2025] Papageorgiou, G., Sarlis, V., Maragoudakis, M., Magnisalis, I., and Tjortjis, C. (2025). Evaluating Faithfulness in Agentic RAG Systems for e-Governance Applications Using LLM-Based Judging Frameworks. Big Data and Cognitive Computing, 9(12). MDPI. DOI: 10.3390/bdcc9120309.

[Park et al., 2023] Park, J. S., O'Brien, J., Cai, C. J., Morris, M. R., Liang, P., and Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. In Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST). ACM. DOI: 10.1145/3586183.3606763.

[Rodriguez et al., 2026] Rodriguez, S., Thangarajah, J., and Winikoff, M. (2026). Requirements-Based Explainability for Multi-agent Systems. Lecture Notes in Computer Science (LNAI), vol. 16370, pages 246–259. Springer. DOI: 10.1007/978-981-95-4969-6_19.

[Rosenfeld and Richardson, 2020] Rosenfeld, A. and Richardson, A. (2020). Why, who, what, when and how about explainability in human-agent systems. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 2020-May, pages 2161–2164. IFAAMAS.

[Soulé et al., 2025] Soulé, J., Jamont, J.-P., Occello, M., Traonouez, L.-M., and Théron, P. (2025). An Organizationally-Oriented Approach to Enhancing Explainability and

Control in Multi-Agent Reinforcement Learning. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), pages 1968–1976. IFAAMAS.

[Turpin et al., 2023] Turpin, M., Michael, J., Perez, E., and Bowman, S. R. (2023). Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting. Advances in Neural Information Processing Systems (NeurIPS), vol. 36. Neural Information Processing Systems Foundation.

[Wai et al., 2024] Wai, K. P., Geng, M., Pateria, S., Subagdja, B., and Tan, A.-H. (2024). Explaining Sequences of Actions in Multi-agent Deep Reinforcement Learning Models. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), vol. 2024-May, pages 2537–2539. IFAAMAS.

[Wang et al., 2023] Wang, G., Xie, Y., Jiang, Y., Mandlekar, A., Xiao, C., Zhu, Y., Fan, L., and Anandkumar, A. (2023). Voyager: An Open-Ended Embodied Agent with Large Language Models. arXiv preprint arXiv:2305.16291. Available at: https://arxiv.org/abs/2305.16291.

[Winikoff et al., 2025] Winikoff, M., Thangarajah, J., and Rodriguez, S. (2025). A Scoresheet for Explainable AI. In Proceedings of the International Joint Conference on Autonomous Agents and Multiagent Systems (AAMAS), pages 2171–2180. IFAAMAS.

[Yan et al., 2025] Yan, E., Burattini, S., Hübner, J. F., and Ricci, A. (2025). A multi-level explainability framework for engineering and understanding BDI agents. Autonomous Agents and Multi-Agent Systems, 39(1). Springer. DOI: 10.1007/s10458-025-09689-6.

[Yao et al., 2023] Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. In Proceedings of the 11th International Conference on Learning Representations (ICLR 2023). International Conference on Learning Representations.

[Georgara et al., 2022 — Gajcin] Gajcin, J. and Dusparic, I. (2024). RACCER: Towards Reachable and Certain Counterfactual Explanations for Reinforcement Learning. In Proceedings of the AAMAS 2024, pages 632–640. IFAAMAS.